Gov 2018: Lab 3 LASSO

Adeline Lo Your name:

Tuesday February 8, 2022

Question 1. Setting up New York Times Annotated Corpus

Question 1.1

Today, we are going to analyze the New York Times Annonated Corpus. From Canvas please download `NYT.RData` and load the file.

This loads a list, `nyt_list`, with the following components:

- train : the document term matrix for the training set
- train_label: an indicator equal to 1 if the story comes from the national desk for each document in the training set
- test: the document term matrix for the test set.
- test_label: an indicator equal to 1 if the story comes from the national desk for each document in the test set

We will work with `train` and `train_label` to build our prediction models. We will use the `test` set to test the fit of our model.

Put these components in individual objects (name each component as a separate object that is easy to understand for you and the reader).

```
library(tidyverse)
```

```
## -- Attaching packages --------------------------------------- tidyverse 1.3.1 --
```

```
## v ggplot2 3.3.5     v purrr   0.3.4
## v tibble  3.1.6     v dplyr   1.0.7
## v tidyr   1.1.4     v stringr 1.4.0
## v readr   2.0.2     v forcats 0.5.1
```

```
## -- Conflicts ------------------------------------------ tidyverse_conflicts() --
## x dplyr::filter() masks stats::filter()
## x dplyr::lag()    masks stats::lag()
```

```
# load in data
load("NYT.RData")

train<- nyt_list$train
train_label<- nyt_list$train_label
test<- nyt_list$test
test_label<- nyt_list$test_label

# seperate training and testing data
train.df <- data.frame(nyt_list$train, nyt_list$train_label) %>%
  mutate(train_label = nyt_list.train_label) %>%
```

```
  select(!nyt_list.train_label)

test.df <- data.frame(nyt_list$test, nyt_list$test_label) %>%
  mutate(test_label = nyt_list.test_label) %>%
  select(!nyt_list.test_label)
```

Question 1.2

Print the dimensions of the train and test set. What is the ratio of n to the number of covariates?

Note that the `train` and `test` matrices do not contain a column for the labels. Combine the dtm and labels into two data frames for the train set and for the test set.

```
# print data dimensions - returns columns and rows
dim(train)
```

```
## [1]  200 1000
```

```
dim(test)
```

```
## [1]   88 1000
```

```
# ratios of columns(covariates) to rows(n)

nrow(train) / ncol(train)
```

```
## [1] 0.2
```

```
nrow(test) / ncol(test)
```

```
## [1] 0.088
```

2. Linear Probability Model

Question 2.1

We are ready to apply a linear probability model to perform classification. Using the `lm` function regress `train_label` against all the words in train. To do this, note that you can include all the variable in a regression using the following syntax: `full_reg <- lm(train_label ~ . , data = train.df)`

The `~.` tells R to include all the variables in the data frame.

Analyze the coefficients from full_reg , what do you notice? Specifically, what happens to the number of coefficients in the model?

```
# run regression

full_ref <- lm(train_label ~ ., data = train.df)

summary(full_ref)
```

```
##
## Call:
## lm(formula = train_label ~ ., data = train.df)
##
## Residuals:
## ALL 200 residuals are 0: no residual degrees of freedom!
```

```
##
## Coefficients: (801 not defined because of singularities)
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.834089        NaN     NaN      NaN
## mr            0.002376        NaN     NaN      NaN
## year         -0.135075        NaN     NaN      NaN
## state        -0.131555        NaN     NaN      NaN
## vote          0.082484        NaN     NaN      NaN
## bush          0.038113        NaN     NaN      NaN
## elect        -0.021215        NaN     NaN      NaN
## time          0.110133        NaN     NaN      NaN
## peopl        -0.323673        NaN     NaN      NaN
## democrat     -0.215114        NaN     NaN      NaN
## republican    0.841856        NaN     NaN      NaN
## kerri        -0.244728        NaN     NaN      NaN
## day           0.168282        NaN     NaN      NaN
## percent       0.003585        NaN     NaN      NaN
## voter         0.104117        NaN     NaN      NaN
## presid        0.290382        NaN     NaN      NaN
## work          0.131921        NaN     NaN      NaN
## compani       0.166860        NaN     NaN      NaN
## make         -0.242899        NaN     NaN      NaN
## million      -0.408072        NaN     NaN      NaN
## campaign     -0.264775        NaN     NaN      NaN
## poll          0.215594        NaN     NaN      NaN
## american     -0.291735        NaN     NaN      NaN
## call          0.544669        NaN     NaN      NaN
## nation       -0.147124        NaN     NaN      NaN
## play         -0.019157        NaN     NaN      NaN
## report        0.499244        NaN     NaN      NaN
## X000          0.247259        NaN     NaN      NaN
## senat         0.095396        NaN     NaN      NaN
## team          0.318106        NaN     NaN      NaN
## X1            0.435223        NaN     NaN      NaN
## ms           -0.584836        NaN     NaN      NaN
## show          0.234104        NaN     NaN      NaN
## race         -0.056761        NaN     NaN      NaN
## week         -0.413232        NaN     NaN      NaN
## back          0.074105        NaN     NaN      NaN
## unit         -0.396167        NaN     NaN      NaN
## citi         -0.500861        NaN     NaN      NaN
## includ        0.797823        NaN     NaN      NaN
## run          -0.301010        NaN     NaN      NaN
## york          0.390734        NaN     NaN      NaN
## made          0.689005        NaN     NaN      NaN
## long         -0.316295        NaN     NaN      NaN
## group        -0.368647        NaN     NaN      NaN
## offici        0.140978        NaN     NaN      NaN
## hous         -0.285889        NaN     NaN      NaN
## season       -0.134547        NaN     NaN      NaN
## game         -0.100964        NaN     NaN      NaN
## X2           -0.497383        NaN     NaN      NaN
## world         0.202757        NaN     NaN      NaN
## govern       -0.251873        NaN     NaN      NaN
```

```
## countri       0.680269        NaN     NaN      NaN
## john         -0.988063        NaN     NaN      NaN
## parti        -0.738360        NaN     NaN      NaN
## support      -0.799493        NaN     NaN      NaN
## point        -0.917728        NaN     NaN      NaN
## home         -0.345326        NaN     NaN      NaN
## polit        -0.248197        NaN     NaN      NaN
## close        -0.280419        NaN     NaN      NaN
## news         -0.369641        NaN     NaN      NaN
## manag        -0.275981        NaN     NaN      NaN
## challeng     -0.160019        NaN     NaN      NaN
## end           0.506465        NaN     NaN      NaN
## win           0.150458        NaN     NaN      NaN
## don           0.671808        NaN     NaN      NaN
## part         -0.612541        NaN     NaN      NaN
## ballot        0.427791        NaN     NaN      NaN
## start         0.286078        NaN     NaN      NaN
## court         0.139476        NaN     NaN      NaN
## offic         0.039450        NaN     NaN      NaN
## won           1.502998        NaN     NaN      NaN
## recent        0.130824        NaN     NaN      NaN
## ad           -0.881173        NaN     NaN      NaN
## month         0.531073        NaN     NaN      NaN
## candid        0.731037        NaN     NaN      NaN
## line         -1.080072        NaN     NaN      NaN
## gener         0.565095        NaN     NaN      NaN
## night         0.278401        NaN     NaN      NaN
## expect       -1.072608        NaN     NaN      NaN
## high          0.539800        NaN     NaN      NaN
## major        -0.481338        NaN     NaN      NaN
## number        0.332995        NaN     NaN      NaN
## lead          0.065598        NaN     NaN      NaN
## ago           0.183364        NaN     NaN      NaN
## issu         -0.768440        NaN     NaN      NaN
## left         -0.050068        NaN     NaN      NaN
## execut        0.954717        NaN     NaN      NaN
## director     -0.611593        NaN     NaN      NaN
## repres       -0.630897        NaN     NaN      NaN
## X2000        -0.810765        NaN     NaN      NaN
## turn          0.035846        NaN     NaN      NaN
## earli         0.019776        NaN     NaN      NaN
## chief         0.215560        NaN     NaN      NaN
## dr           -0.018431        NaN     NaN      NaN
## return       -0.004168        NaN     NaN      NaN
## busi          0.092464        NaN     NaN      NaN
## good          0.392070        NaN     NaN      NaN
## plan          0.135742        NaN     NaN      NaN
## base          0.070441        NaN     NaN      NaN
## open         -0.293394        NaN     NaN      NaN
## list          0.203822        NaN     NaN      NaN
## told         -0.324829        NaN     NaN      NaN
## center        0.025516        NaN     NaN      NaN
## ohio         -0.644758        NaN     NaN      NaN
## X10           0.897142        NaN     NaN      NaN
```

```
## ve            0.524292       NaN     NaN      NaN
## job          -0.212918       NaN     NaN      NaN
## face         -0.017457       NaN     NaN      NaN
## worker       -1.106879       NaN     NaN      NaN
## thing         1.036948       NaN     NaN      NaN
## big           0.376632       NaN     NaN      NaN
## case         -0.444223       NaN     NaN      NaN
## victori      -0.157730       NaN     NaN      NaN
## X5           -0.706252       NaN     NaN      NaN
## hour          0.227252       NaN     NaN      NaN
## result       -0.457804       NaN     NaN      NaN
## florida       0.215252       NaN     NaN      NaN
## record       -1.530590       NaN     NaN      NaN
## X3            0.324894       NaN     NaN      NaN
## talk         -0.990877       NaN     NaN      NaN
## china        -0.229115       NaN     NaN      NaN
## sign          0.170090       NaN     NaN      NaN
## set           0.132477       NaN     NaN      NaN
## live          0.949188       NaN     NaN      NaN
## put          -1.520416       NaN     NaN      NaN
## offer        -0.031564       NaN     NaN      NaN
## iraq         -0.056756       NaN     NaN      NaN
## public        0.220849       NaN     NaN      NaN
## presidenti    0.130378       NaN     NaN      NaN
## coach        -0.021988       NaN     NaN      NaN
## move          0.363748       NaN     NaN      NaN
## market        0.754294       NaN     NaN      NaN
## tuesday       0.767870       NaN     NaN      NaN
## sunday        1.746363       NaN     NaN      NaN
## famili       -0.158813       NaN     NaN      NaN
## polic        -0.366117       NaN     NaN      NaN
## receiv       -0.905729       NaN     NaN      NaN
## player       -0.577244       NaN     NaN      NaN
## person        0.174298       NaN     NaN      NaN
## monday        0.494506       NaN     NaN      NaN
## servic       -0.096163       NaN     NaN      NaN
## problem      -0.683291       NaN     NaN      NaN
## forc         -0.286810       NaN     NaN      NaN
## final        -0.177616       NaN     NaN      NaN
## system        0.109223       NaN     NaN      NaN
## man          -0.014515       NaN     NaN      NaN
## kill          0.044795       NaN     NaN      NaN
## war          -0.336227       NaN     NaN      NaN
## lot           0.281514       NaN     NaN      NaN
## question      1.761310       NaN     NaN      NaN
## trade         0.134093       NaN     NaN      NaN
## counti        1.544319       NaN     NaN      NaN
## yesterday     1.355226       NaN     NaN      NaN
## school        0.658244       NaN     NaN      NaN
## import        0.287562       NaN     NaN      NaN
## side          1.235257       NaN     NaN      NaN
## X2004        -0.312573       NaN     NaN      NaN
## cost          0.528937       NaN     NaN      NaN
## washington    0.167304       NaN     NaN      NaN
```

```
## univers       0.778017        NaN     NaN      NaN
## program      -0.228423        NaN     NaN      NaN
## life         -0.052566        NaN     NaN      NaN
## lost         -1.016005        NaN     NaN      NaN
## seat          0.046281        NaN     NaN      NaN
## member        0.567511        NaN     NaN      NaN
## hand         -0.518461        NaN     NaN      NaN
## deal         -0.172299        NaN     NaN      NaN
## intern        1.134476        NaN     NaN      NaN
## X4            0.430497        NaN     NaN      NaN
## employe      -0.272915        NaN     NaN      NaN
## term         -0.837326        NaN     NaN      NaN
## contract      0.098675        NaN     NaN      NaN
## find          0.330751        NaN     NaN      NaN
## larg         -1.034846        NaN     NaN      NaN
## health        0.096763        NaN     NaN      NaN
## interest      1.202402        NaN     NaN      NaN
## research     -0.289364        NaN     NaN      NaN
## money         0.153078        NaN     NaN      NaN
## street        0.805491        NaN     NaN      NaN
## found         0.436493        NaN     NaN      NaN
## product       0.175038        NaN     NaN      NaN
## secur         0.280076        NaN     NaN      NaN
## white         0.319960        NaN     NaN      NaN
## book          0.011064        NaN     NaN      NaN
## inform       -0.106826        NaN     NaN      NaN
## seri         -0.029016        NaN     NaN      NaN
## care          1.142920        NaN     NaN      NaN
## price         0.082571        NaN     NaN      NaN
## televis       0.451963        NaN     NaN      NaN
## site         -0.411784        NaN     NaN      NaN
## law           0.361449        NaN     NaN      NaN
## red           0.014302        NaN     NaN      NaN
## head         -0.978863        NaN     NaN      NaN
## decis        -0.771066        NaN     NaN      NaN
## al           -0.801393        NaN     NaN      NaN
## america      -0.242332        NaN     NaN      NaN
## rule          0.438728        NaN     NaN      NaN
## remain       -0.371184        NaN     NaN      NaN
## X20          -0.365326        NaN     NaN      NaN
## X30           0.882641        NaN     NaN      NaN
## increas             NA         NA      NA       NA
## share               NA         NA      NA       NA
## agenc               NA         NA      NA       NA
## critic              NA         NA      NA       NA
## music               NA         NA      NA       NA
## X6                  NA         NA      NA       NA
## area                NA         NA      NA       NA
## count               NA         NA      NA       NA
## continu             NA         NA      NA       NA
## local               NA         NA      NA       NA
## effort              NA         NA      NA       NA
## industri            NA         NA      NA       NA
## past                NA         NA      NA       NA
```

```
## governor            NA         NA      NA       NA
## network             NA         NA      NA       NA
## half                NA         NA      NA       NA
## film                NA         NA      NA       NA
## build               NA         NA      NA       NA
## organ               NA         NA      NA       NA
## union               NA         NA      NA       NA
## bank                NA         NA      NA       NA
## hard                NA         NA      NA       NA
## held                NA         NA      NA       NA
## quarter             NA         NA      NA       NA
## south               NA         NA      NA       NA
## develop             NA         NA      NA       NA
## produc              NA         NA      NA       NA
## pass                NA         NA      NA       NA
## leagu               NA         NA      NA       NA
## matter              NA         NA      NA       NA
## oil                 NA         NA      NA       NA
## children            NA         NA      NA       NA
## feel                NA         NA      NA       NA
## attack              NA         NA      NA       NA
## top                 NA         NA      NA       NA
## boston              NA         NA      NA       NA
## defeat              NA         NA      NA       NA
## feder               NA         NA      NA       NA
## interview           NA         NA      NA       NA
## volunt              NA         NA      NA       NA
## pay                 NA         NA      NA       NA
## kind                NA         NA      NA       NA
## leader              NA         NA      NA       NA
## score               NA         NA      NA       NA
## oper                NA         NA      NA       NA
## thousand            NA         NA      NA       NA
## rais                NA         NA      NA       NA
## men                 NA         NA      NA       NA
## met                 NA         NA      NA       NA
## tax                 NA         NA      NA       NA
## project             NA         NA      NA       NA
## west                NA         NA      NA       NA
## control             NA         NA      NA       NA
## polici              NA         NA      NA       NA
## yard                NA         NA      NA       NA
## jet                 NA         NA      NA       NA
## billion             NA         NA      NA       NA
## field               NA         NA      NA       NA
## bill                NA         NA      NA       NA
## led                 NA         NA      NA       NA
## district            NA         NA      NA       NA
## technolog           NA         NA      NA       NA
## perform             NA         NA      NA       NA
## X11                 NA         NA      NA       NA
## giant               NA         NA      NA       NA
## small               NA         NA      NA       NA
## north               NA         NA      NA       NA
```

```
## conserv          NA         NA      NA       NA
## effect           NA         NA      NA       NA
## watch            NA         NA      NA       NA
## gave             NA         NA      NA       NA
## young            NA         NA      NA       NA
## releas           NA         NA      NA       NA
## guy              NA         NA      NA       NA
## X12              NA         NA      NA       NA
## justic           NA         NA      NA       NA
## colleg           NA         NA      NA       NA
## death            NA         NA      NA       NA
## lawyer           NA         NA      NA       NA
## water            NA         NA      NA       NA
## power            NA         NA      NA       NA
## administr        NA         NA      NA       NA
## low              NA         NA      NA       NA
## sale             NA         NA      NA       NA
## charg            NA         NA      NA       NA
## X50              NA         NA      NA       NA
## stori            NA         NA      NA       NA
## iraqi            NA         NA      NA       NA
## clear            NA         NA      NA       NA
## georg            NA         NA      NA       NA
## black            NA         NA      NA       NA
## advertis         NA         NA      NA       NA
## X7               NA         NA      NA       NA
## X8               NA         NA      NA       NA
## women            NA         NA      NA       NA
## carri            NA         NA      NA       NA
## town             NA         NA      NA       NA
## success          NA         NA      NA       NA
## thoma            NA         NA      NA       NA
## suggest          NA         NA      NA       NA
## minut            NA         NA      NA       NA
## board            NA         NA      NA       NA
## stop             NA         NA      NA       NA
## defens           NA         NA      NA       NA
## posit            NA         NA      NA       NA
## decid            NA         NA      NA       NA
## X9               NA         NA      NA       NA
## leav             NA         NA      NA       NA
## commun           NA         NA      NA       NA
## studi            NA         NA      NA       NA
## meet             NA         NA      NA       NA
## die              NA         NA      NA       NA
## visit            NA         NA      NA       NA
## shop             NA         NA      NA       NA
## spent            NA         NA      NA       NA
## direct           NA         NA      NA       NA
## free             NA         NA      NA       NA
## lose             NA         NA      NA       NA
## note             NA         NA      NA       NA
## incumb           NA         NA      NA       NA
## involv           NA         NA      NA       NA
```

```
## media              NA         NA       NA       NA
## front              NA         NA       NA       NA
## form               NA         NA       NA       NA
## wait               NA         NA       NA       NA
## claim              NA         NA       NA       NA
## yanke              NA         NA       NA       NA
## today              NA         NA       NA       NA
## author             NA         NA       NA       NA
## didn               NA         NA       NA       NA
## great              NA         NA       NA       NA
## fight              NA         NA       NA       NA
## serv               NA         NA       NA       NA
## senior             NA         NA       NA       NA
## cast               NA         NA       NA       NA
## economi            NA         NA       NA       NA
## began              NA         NA       NA       NA
## gain               NA         NA       NA       NA
## idea               NA         NA       NA       NA
## pick               NA         NA       NA       NA
## morn               NA         NA       NA       NA
## comput             NA         NA       NA       NA
## approv             NA         NA       NA       NA
## X15                NA         NA       NA       NA
## militari           NA         NA       NA       NA
## aid                NA         NA       NA       NA
## turnout            NA         NA       NA       NA
## california         NA         NA       NA       NA
## store              NA         NA       NA       NA
## chairman           NA         NA       NA       NA
## figur              NA         NA       NA       NA
## X2003              NA         NA       NA       NA
## reach              NA         NA       NA       NA
## hold               NA         NA       NA       NA
## east               NA         NA       NA       NA
## measur             NA         NA       NA       NA
## begin              NA         NA       NA       NA
## sox                NA         NA       NA       NA
## edward             NA         NA       NA       NA
## japan              NA         NA       NA       NA
## rate               NA         NA       NA       NA
## evid               NA         NA       NA       NA
## real               NA         NA       NA       NA
## elector            NA         NA       NA       NA
## X14                NA         NA       NA       NA
## cancer             NA         NA       NA       NA
## spend              NA         NA       NA       NA
## view               NA         NA       NA       NA
## committe           NA         NA       NA       NA
## histori            NA         NA       NA       NA
## chanc              NA         NA       NA       NA
## addit              NA         NA       NA       NA
## wife               NA         NA       NA       NA
## travel             NA         NA       NA       NA
## bring              NA         NA       NA       NA
```

```
## muslim              NA         NA      NA       NA
## analyst             NA         NA      NA       NA
## X2002               NA         NA      NA       NA
## regist              NA         NA      NA       NA
## judg                NA         NA      NA       NA
## stand               NA         NA      NA       NA
## friday              NA         NA      NA       NA
## fox                 NA         NA      NA       NA
## data                NA         NA      NA       NA
## full                NA         NA      NA       NA
## sell                NA         NA      NA       NA
## survey              NA         NA      NA       NA
## decad               NA         NA      NA       NA
## strong              NA         NA      NA       NA
## write               NA         NA      NA       NA
## finish              NA         NA      NA       NA
## popular             NA         NA      NA       NA
## bad                 NA         NA      NA       NA
## averag              NA         NA      NA       NA
## declin              NA         NA      NA       NA
## train               NA         NA      NA       NA
## messag              NA         NA      NA       NA
## insur               NA         NA      NA       NA
## protect             NA         NA      NA       NA
## requir              NA         NA      NA       NA
## creat               NA         NA      NA       NA
## machin              NA         NA      NA       NA
## woman               NA         NA      NA       NA
## global              NA         NA      NA       NA
## loss                NA         NA      NA       NA
## estim               NA         NA      NA       NA
## spokesman           NA         NA      NA       NA
## grow                NA         NA      NA       NA
## expert              NA         NA      NA       NA
## thought             NA         NA      NA       NA
## complet             NA         NA      NA       NA
## design              NA         NA      NA       NA
## respons             NA         NA      NA       NA
## love                NA         NA      NA       NA
## custom              NA         NA      NA       NA
## independ            NA         NA      NA       NA
## car                 NA         NA      NA       NA
## friend              NA         NA      NA       NA
## star                NA         NA      NA       NA
## mail                NA         NA      NA       NA
## oppon               NA         NA      NA       NA
## account             NA         NA      NA       NA
## texa                NA         NA      NA       NA
## vice                NA         NA      NA       NA
## prison              NA         NA      NA       NA
## fact                NA         NA      NA       NA
## resid               NA         NA      NA       NA
## corpor              NA         NA      NA       NA
## basebal             NA         NA      NA       NA
```

```
## seek              NA         NA      NA       NA
## foreign           NA         NA      NA       NA
## patient           NA         NA      NA       NA
## announc           NA         NA      NA       NA
## david             NA         NA      NA       NA
## earlier           NA         NA      NA       NA
## order             NA         NA      NA       NA
## appeal            NA         NA      NA       NA
## futur             NA         NA      NA       NA
## X18               NA         NA      NA       NA
## stock             NA         NA      NA       NA
## god               NA         NA      NA       NA
## flight            NA         NA      NA       NA
## marriag           NA         NA      NA       NA
## cover             NA         NA      NA       NA
## church            NA         NA      NA       NA
## air               NA         NA      NA       NA
## read              NA         NA      NA       NA
## main              NA         NA      NA       NA
## improv            NA         NA      NA       NA
## mart              NA         NA      NA       NA
## dollar            NA         NA      NA       NA
## X25               NA         NA      NA       NA
## press             NA         NA      NA       NA
## fail              NA         NA      NA       NA
## competit          NA         NA      NA       NA
## benefit           NA         NA      NA       NA
## art               NA         NA      NA       NA
## cut               NA         NA      NA       NA
## guard             NA         NA      NA       NA
## approach          NA         NA      NA       NA
## demand            NA         NA      NA       NA
## digit             NA         NA      NA       NA
## dozen             NA         NA      NA       NA
## crowd             NA         NA      NA       NA
## san               NA         NA      NA       NA
## richard           NA         NA      NA       NA
## learn             NA         NA      NA       NA
## stage             NA         NA      NA       NA
## chines            NA         NA      NA       NA
## confer            NA         NA      NA       NA
## retir             NA         NA      NA       NA
## medic             NA         NA      NA       NA
## airlin            NA         NA      NA       NA
## articl            NA         NA      NA       NA
## agre              NA         NA      NA       NA
## telephon          NA         NA      NA       NA
## financi           NA         NA      NA       NA
## mark              NA         NA      NA       NA
## margin            NA         NA      NA       NA
## beat              NA         NA      NA       NA
## phone             NA         NA      NA       NA
## hear              NA         NA      NA       NA
## hit               NA         NA      NA       NA
```

```
## schedul            NA         NA      NA       NA
## father             NA         NA      NA       NA
## X100               NA         NA      NA       NA
## kid                NA         NA      NA       NA
## flu                NA         NA      NA       NA
## file               NA         NA      NA       NA
## ran                NA         NA      NA       NA
## wide               NA         NA      NA       NA
## invest             NA         NA      NA       NA
## push               NA         NA      NA       NA
## activ              NA         NA      NA       NA
## cheney             NA         NA      NA       NA
## action             NA         NA      NA       NA
## ball               NA         NA      NA       NA
## prepar             NA         NA      NA       NA
## drop               NA         NA      NA       NA
## miss               NA         NA      NA       NA
## contest            NA         NA      NA       NA
## room               NA         NA      NA       NA
## mile               NA         NA      NA       NA
## retail             NA         NA      NA       NA
## X60                NA         NA      NA       NA
## class              NA         NA      NA       NA
## miami              NA         NA      NA       NA
## relat              NA         NA      NA       NA
## elgindi            NA         NA      NA       NA
## web                NA         NA      NA       NA
## post               NA         NA      NA       NA
## test               NA         NA      NA       NA
## angel              NA         NA      NA       NA
## publish            NA         NA      NA       NA
## michael            NA         NA      NA       NA
## X24                NA         NA      NA       NA
## moment             NA         NA      NA       NA
## conduct            NA         NA      NA       NA
## level              NA         NA      NA       NA
## short              NA         NA      NA       NA
## largest            NA         NA      NA       NA
## wednesday          NA         NA      NA       NA
## stadium            NA         NA      NA       NA
## replac             NA         NA      NA       NA
## econom             NA         NA      NA       NA
## firm               NA         NA      NA       NA
## age                NA         NA      NA       NA
## ga                 NA         NA      NA       NA
## X40                NA         NA      NA       NA
## collect            NA         NA      NA       NA
## featur             NA         NA      NA       NA
## randolph           NA         NA      NA       NA
## biggest            NA         NA      NA       NA
## capit              NA         NA      NA       NA
## region             NA         NA      NA       NA
## legal              NA         NA      NA       NA
## appli              NA         NA      NA       NA
```

```
## contribut          NA         NA      NA       NA
## investig           NA         NA      NA       NA
## fire               NA         NA      NA       NA
## argu               NA         NA      NA       NA
## sport              NA         NA      NA       NA
## imag               NA         NA      NA       NA
## step               NA         NA      NA       NA
## advis              NA         NA      NA       NA
## fill               NA         NA      NA       NA
## debat              NA         NA      NA       NA
## experi             NA         NA      NA       NA
## japanes            NA         NA      NA       NA
## saturday           NA         NA      NA       NA
## swing              NA         NA      NA       NA
## review             NA         NA      NA       NA
## minor              NA         NA      NA       NA
## goal               NA         NA      NA       NA
## professor          NA         NA      NA       NA
## vike               NA         NA      NA       NA
## drug               NA         NA      NA       NA
## neal               NA         NA      NA       NA
## total              NA         NA      NA       NA
## wal                NA         NA      NA       NA
## theater            NA         NA      NA       NA
## block              NA         NA      NA       NA
## page               NA         NA      NA       NA
## X16                NA         NA      NA       NA
## energi             NA         NA      NA       NA
## fan                NA         NA      NA       NA
## missionari         NA         NA      NA       NA
## enter              NA         NA      NA       NA
## opera              NA         NA      NA       NA
## battl              NA         NA      NA       NA
## emerg              NA         NA      NA       NA
## son                NA         NA      NA       NA
## drive              NA         NA      NA       NA
## act                NA         NA      NA       NA
## opposit            NA         NA      NA       NA
## space              NA         NA      NA       NA
## promis             NA         NA      NA       NA
## mind               NA         NA      NA       NA
## X13                NA         NA      NA       NA
## ll                 NA         NA      NA       NA
## minnesota          NA         NA      NA       NA
## oct                NA         NA      NA       NA
## social             NA         NA      NA       NA
## tie                NA         NA      NA       NA
## fourth             NA         NA      NA       NA
## determin           NA         NA      NA       NA
## regul              NA         NA      NA       NA
## sens               NA         NA      NA       NA
## huge               NA         NA      NA       NA
## clinton            NA         NA      NA       NA
## newspap            NA         NA      NA       NA
```

```
## comment             NA         NA      NA       NA
## central             NA         NA      NA       NA
## pictur              NA         NA      NA       NA
## winner              NA         NA      NA       NA
## tradit              NA         NA      NA       NA
## propos              NA         NA      NA       NA
## earn                NA         NA      NA       NA
## minist              NA         NA      NA       NA
## X17                 NA         NA      NA       NA
## squar               NA         NA      NA       NA
## track               NA         NA      NA       NA
## shot                NA         NA      NA       NA
## audienc             NA         NA      NA       NA
## staff               NA         NA      NA       NA
## buy                 NA         NA      NA       NA
## quickli             NA         NA      NA       NA
## period              NA         NA      NA       NA
## hotel               NA         NA      NA       NA
## compar              NA         NA      NA       NA
## fear                NA         NA      NA       NA
## difficult           NA         NA      NA       NA
## kidd                NA         NA      NA       NA
## refer               NA         NA      NA       NA
## philadelphia        NA         NA      NA       NA
## depart              NA         NA      NA       NA
## footbal             NA         NA      NA       NA
## disput              NA         NA      NA       NA
## palestinian         NA         NA      NA       NA
## speak               NA         NA      NA       NA
## stay                NA         NA      NA       NA
## similar             NA         NA      NA       NA
## neighborhood        NA         NA      NA       NA
## statement           NA         NA      NA       NA
## intellig            NA         NA      NA       NA
## join                NA         NA      NA       NA
## ventur              NA         NA      NA       NA
## profit              NA         NA      NA       NA
## X500                NA         NA      NA       NA
## potenti             NA         NA      NA       NA
## divis               NA         NA      NA       NA
## favor               NA         NA      NA       NA
## present             NA         NA      NA       NA
## injur               NA         NA      NA       NA
## prevent             NA         NA      NA       NA
## screen              NA         NA      NA       NA
## hundr               NA         NA      NA       NA
## jewish              NA         NA      NA       NA
## owner               NA         NA      NA       NA
## korean              NA         NA      NA       NA
## arrest              NA         NA      NA       NA
## insid               NA         NA      NA       NA
## signal              NA         NA      NA       NA
## institut            NA         NA      NA       NA
## limit               NA         NA      NA       NA
```

```
## accus              NA         NA       NA       NA
## net                NA         NA       NA       NA
## type               NA         NA       NA       NA
## agent              NA         NA       NA       NA
## understand         NA         NA       NA       NA
## ralli              NA         NA       NA       NA
## precinct           NA         NA       NA       NA
## consum             NA         NA       NA       NA
## nov                NA         NA       NA       NA
## event              NA         NA       NA       NA
## titl               NA         NA       NA       NA
## promot             NA         NA       NA       NA
## lake               NA         NA       NA       NA
## christian          NA         NA       NA       NA
## commiss            NA         NA       NA       NA
## hospit             NA         NA       NA       NA
## summer             NA         NA       NA       NA
## chicago            NA         NA       NA       NA
## fund               NA         NA       NA       NA
## break.             NA         NA       NA       NA
## septemb            NA         NA       NA       NA
## coverag            NA         NA       NA       NA
## realiti            NA         NA       NA       NA
## terror             NA         NA       NA       NA
## reduc              NA         NA       NA       NA
## food               NA         NA       NA       NA
## doesn              NA         NA       NA       NA
## peterson           NA         NA       NA       NA
## explain            NA         NA       NA       NA
## human              NA         NA       NA       NA
## predict            NA         NA       NA       NA
## easili             NA         NA       NA       NA
## suprem             NA         NA       NA       NA
## gay                NA         NA       NA       NA
## rank               NA         NA       NA       NA
## western            NA         NA       NA       NA
## touchdown          NA         NA       NA       NA
## brother            NA         NA       NA       NA
## lower              NA         NA       NA       NA
## attent             NA         NA       NA       NA
## arriv              NA         NA       NA       NA
## respond            NA         NA       NA       NA
## send               NA         NA       NA       NA
## trial              NA         NA       NA       NA
## offens             NA         NA       NA       NA
## aggress            NA         NA       NA       NA
## cleveland          NA         NA       NA       NA
## contend            NA         NA       NA       NA
## broadcast          NA         NA       NA       NA
## X19                NA         NA       NA       NA
## parent             NA         NA       NA       NA
## speech             NA         NA       NA       NA
## park               NA         NA       NA       NA
## iowa               NA         NA       NA       NA
```

```
## congression         NA         NA      NA       NA
## marathon            NA         NA      NA       NA
## pennsylvania        NA         NA      NA       NA
## threat              NA         NA      NA       NA
## surpris             NA         NA      NA       NA
## arafat              NA         NA      NA       NA
## wrong               NA         NA      NA       NA
## confid              NA         NA      NA       NA
## artist              NA         NA      NA       NA
## door                NA         NA      NA       NA
## land                NA         NA      NA       NA
## word                NA         NA      NA       NA
## india               NA         NA      NA       NA
## prove               NA         NA      NA       NA
## club                NA         NA      NA       NA
## focu                NA         NA      NA       NA
## veteran             NA         NA      NA       NA
## ground              NA         NA      NA       NA
## estat               NA         NA      NA       NA
## match               NA         NA      NA       NA
## william             NA         NA      NA       NA
## singl               NA         NA      NA       NA
## box                 NA         NA      NA       NA
## johnson             NA         NA      NA       NA
## prime               NA         NA      NA       NA
## paid                NA         NA      NA       NA
## cultur              NA         NA      NA       NA
## common              NA         NA      NA       NA
## milit               NA         NA      NA       NA
## rove                NA         NA      NA       NA
## absente             NA         NA      NA       NA
## sept                NA         NA      NA       NA
## individu            NA         NA      NA       NA
## wrote               NA         NA      NA       NA
## growth              NA         NA      NA       NA
## student             NA         NA      NA       NA
## english             NA         NA      NA       NA
## pro                 NA         NA      NA       NA
## jim                 NA         NA      NA       NA
## consult             NA         NA      NA       NA
## knick               NA         NA      NA       NA
## cb                  NA         NA      NA       NA
## paul                NA         NA      NA       NA
## warn                NA         NA      NA       NA
## negoti              NA         NA      NA       NA
## subject             NA         NA      NA       NA
## oppos               NA         NA      NA       NA
## suffer              NA         NA      NA       NA
## latest              NA         NA      NA       NA
## attract             NA         NA      NA       NA
## check               NA         NA      NA       NA
## villag              NA         NA      NA       NA
## river               NA         NA      NA       NA
## troubl              NA         NA      NA       NA
```

```
## condit              NA         NA      NA       NA
## rest                NA         NA      NA       NA
## process             NA         NA      NA       NA
## educ                NA         NA      NA       NA
## natur               NA         NA      NA       NA
## doubt               NA         NA      NA       NA
## novemb              NA         NA      NA       NA
## heart               NA         NA      NA       NA
## size                NA         NA      NA       NA
## hire                NA         NA      NA       NA
## manhattan           NA         NA      NA       NA
## photograph          NA         NA      NA       NA
## fell                NA         NA      NA       NA
## initi               NA         NA      NA       NA
## gore                NA         NA      NA       NA
## airport             NA         NA      NA       NA
## vaccin              NA         NA      NA       NA
## simpli              NA         NA      NA       NA
## wage                NA         NA      NA       NA
## insurg              NA         NA      NA       NA
## tom                 NA         NA      NA       NA
## focus               NA         NA      NA       NA
## cloth               NA         NA      NA       NA
## wall                NA         NA      NA       NA
## centuri             NA         NA      NA       NA
## runner              NA         NA      NA       NA
## knew                NA         NA      NA       NA
## carolina            NA         NA      NA       NA
## constitut           NA         NA      NA       NA
## station             NA         NA      NA       NA
## vehicl              NA         NA      NA       NA
## incom               NA         NA      NA       NA
## repeat.             NA         NA      NA       NA
## green               NA         NA      NA       NA
## standard            NA         NA      NA       NA
## revenu              NA         NA      NA       NA
## middl               NA         NA      NA       NA
## engin               NA         NA      NA       NA
## ahead               NA         NA      NA       NA
## accept              NA         NA      NA       NA
## prosecutor          NA         NA      NA       NA
## draw                NA         NA      NA       NA
## fuel                NA         NA      NA       NA
## editor              NA         NA      NA       NA
## felt                NA         NA      NA       NA
## daili               NA         NA      NA       NA
## diseas              NA         NA      NA       NA
## sound               NA         NA      NA       NA
## island              NA         NA      NA       NA
## eye                 NA         NA      NA       NA
## explor              NA         NA      NA       NA
## mother              NA         NA      NA       NA
## championship        NA         NA      NA       NA
## thursday            NA         NA      NA       NA
```

```
## joe                NA         NA       NA       NA
## employ             NA         NA       NA       NA
## spot               NA         NA       NA       NA
## opinion            NA         NA       NA       NA
## movi               NA         NA       NA       NA
## passeng            NA         NA       NA       NA
## avoid              NA         NA       NA       NA
## demonstr           NA         NA       NA       NA
## ill                NA         NA       NA       NA
## jone               NA         NA       NA       NA
## special            NA         NA       NA       NA
## francisco          NA         NA       NA       NA
## dead               NA         NA       NA       NA
## mill               NA         NA       NA       NA
## road               NA         NA       NA       NA
## bodi               NA         NA       NA       NA
## lo                 NA         NA       NA       NA
## search             NA         NA       NA       NA
## practic            NA         NA       NA       NA
## coupl              NA         NA       NA       NA
## israel             NA         NA       NA       NA
## style              NA         NA       NA       NA
## brought            NA         NA       NA       NA
## spoke              NA         NA       NA       NA
## internet           NA         NA       NA       NA
## convent            NA         NA       NA       NA
## struggl            NA         NA       NA       NA
## spread             NA         NA       NA       NA
## heard              NA         NA       NA       NA
## hsbc               NA         NA       NA       NA
## baghdad            NA         NA       NA       NA
## treat              NA         NA       NA       NA
## assist             NA         NA       NA       NA
## X21                NA         NA       NA       NA
## X22                NA         NA       NA       NA
## complain           NA         NA       NA       NA
## shape              NA         NA       NA       NA
## X2001              NA         NA       NA       NA
## brand              NA         NA       NA       NA
## risk               NA         NA       NA       NA
## rise               NA         NA       NA       NA
## blue               NA         NA       NA       NA
## choic              NA         NA       NA       NA
## declar             NA         NA       NA       NA
## origin             NA         NA       NA       NA
## amend              NA         NA       NA       NA
## moder              NA         NA       NA       NA
## britain            NA         NA       NA       NA
## larger             NA         NA       NA       NA
## walk               NA         NA       NA       NA
## mike               NA         NA       NA       NA
## role               NA         NA       NA       NA
## address            NA         NA       NA       NA
## argument           NA         NA       NA       NA
```

```
## introduc          NA        NA      NA       NA
## paper             NA        NA      NA       NA
## england           NA        NA      NA       NA
## sex               NA        NA      NA       NA
## de                NA        NA      NA       NA
## born              NA        NA      NA       NA
## paint             NA        NA      NA       NA
## jame              NA        NA      NA       NA
## welfar            NA        NA      NA       NA
## round             NA        NA      NA       NA
## rock              NA        NA      NA       NA
## correct           NA        NA      NA       NA
## channel           NA        NA      NA       NA
## connect           NA        NA      NA       NA
## surfac            NA        NA      NA       NA
## rush              NA        NA      NA       NA
## radio             NA        NA      NA       NA
## violenc           NA        NA      NA       NA
## feet              NA        NA      NA       NA
## elig              NA        NA      NA       NA
## discuss           NA        NA      NA       NA
## peoplesoft        NA        NA      NA       NA
## canyon            NA        NA      NA       NA
## cite              NA        NA      NA       NA
## neighbor          NA        NA      NA       NA
## factor            NA        NA      NA       NA
## touch             NA        NA      NA       NA
## suit              NA        NA      NA       NA
## houston           NA        NA      NA       NA
## oracl             NA        NA      NA       NA
## percentag         NA        NA      NA       NA
## gun               NA        NA      NA       NA
## hall              NA        NA      NA       NA
## treatment         NA        NA      NA       NA
## injuri            NA        NA      NA       NA
## key               NA        NA      NA       NA
## starbuck          NA        NA      NA       NA
## bob               NA        NA      NA       NA
## girl              NA        NA      NA       NA
## fall              NA        NA      NA       NA
## liber             NA        NA      NA       NA
## express           NA        NA      NA       NA
## add               NA        NA      NA       NA
## insist            NA        NA      NA       NA
## virginia          NA        NA      NA       NA
## scientist         NA        NA      NA       NA
## advanc            NA        NA      NA       NA
## strike            NA        NA      NA       NA
## schumer           NA        NA      NA       NA
## plane             NA        NA      NA       NA
## secretari         NA        NA      NA       NA
## magazin           NA        NA      NA       NA
## husband           NA        NA      NA       NA
## king              NA        NA      NA       NA
```

```
## increasingli        NA         NA      NA       NA
## martin              NA         NA      NA       NA
## attempt             NA         NA      NA       NA
## situat              NA         NA      NA       NA
## troop               NA         NA      NA       NA
## athlet              NA         NA      NA       NA
## monitor             NA         NA      NA       NA
## doctor              NA         NA      NA       NA
## built               NA         NA      NA       NA
## jason               NA         NA      NA       NA
## wade                NA         NA      NA       NA
## defend              NA         NA      NA       NA
## journalist          NA         NA      NA       NA
## circul              NA         NA      NA       NA
## client              NA         NA      NA       NA
## civil               NA         NA      NA       NA
## ticket              NA         NA      NA       NA
## weight              NA         NA      NA       NA
## X80                 NA         NA      NA       NA
## heavili             NA         NA      NA       NA
## appar               NA         NA      NA       NA
## intens              NA         NA      NA       NA
## chain               NA         NA      NA       NA
## pull                NA         NA      NA       NA
## congress            NA         NA      NA       NA
## agreement           NA         NA      NA       NA
## garden              NA         NA      NA       NA
## video               NA         NA      NA       NA
## meant               NA         NA      NA       NA
## expand              NA         NA      NA       NA
## captur              NA         NA      NA       NA
## domin               NA         NA      NA       NA
## arab                NA         NA      NA       NA
## provision           NA         NA      NA       NA
## caught              NA         NA      NA       NA
## robert              NA         NA      NA       NA
## sheik               NA         NA      NA       NA
## armi                NA         NA      NA       NA
## answer              NA         NA      NA       NA
## marin               NA         NA      NA       NA
## mexico              NA         NA      NA       NA
## commit              NA         NA      NA       NA
## classic             NA         NA      NA       NA
## shift               NA         NA      NA       NA
## faith               NA         NA      NA       NA
## previou             NA         NA      NA       NA
## annual              NA         NA      NA       NA
## forward             NA         NA      NA       NA
## physic              NA         NA      NA       NA
## mix                 NA         NA      NA       NA
## X45                 NA         NA      NA       NA
## basketbal           NA         NA      NA       NA
## dolphin             NA         NA      NA       NA
## combin              NA         NA      NA       NA
```

```
## refus               NA         NA      NA       NA
## wisconsin           NA         NA      NA       NA
## sold                NA         NA      NA       NA
## van                 NA         NA      NA       NA
## remind              NA         NA      NA       NA
## roll                NA         NA      NA       NA
## draft               NA         NA      NA       NA
## surviv              NA         NA      NA       NA
## expens              NA         NA      NA       NA
## acknowledg          NA         NA      NA       NA
## scene               NA         NA      NA       NA
## mayor               NA         NA      NA       NA
## target              NA         NA      NA       NA
## contact             NA         NA      NA       NA
## lewi                NA         NA      NA       NA
## opportun            NA         NA      NA       NA
## request             NA         NA      NA       NA
## stake               NA         NA      NA       NA
## fraud               NA         NA      NA       NA
## poor                NA         NA      NA       NA
## foot                NA         NA      NA       NA
## pretti              NA         NA      NA       NA
## readi               NA         NA      NA       NA
## milwauke            NA         NA      NA       NA
## handl               NA         NA      NA       NA
## career              NA         NA      NA       NA
## arnel               NA         NA      NA       NA
## voic                NA         NA      NA       NA
## identifi            NA         NA      NA       NA
## X0                  NA         NA      NA       NA
## X23                 NA         NA      NA       NA
## merger              NA         NA      NA       NA
##
## Residual standard error: NaN on 0 degrees of freedom
## Multiple R-squared:      1,  Adjusted R-squared:    NaN
## F-statistic:   NaN on 199 and 0 DF,  p-value: NA
```

```
# number of NA coefficients in the model
length(which(is.na(full_ref$coeff)==T))
```

```
## [1] 801
```

There are a lot of covariates, none of which have significant effects and about 50% of which have NA values as coefficients.

Question 2.2

We are now going to make predictions using the training data and the test data and compare their properties.

Using the `predict` function, make predictions for all observations in the training set. Then, classify the documents as national or not using a threshold of 0.5. Assess your classification to the actual data. Create a 2x2 table of the predicted train labels and true train label and note your findings.

```
# train is a matrix
train_pred <- predict(full_ref, as.data.frame(train))
```

```
## Warning in predict.lm(full_ref, as.data.frame(train)): prediction from a rank-
## deficient fit may be misleading
```

```
class_doc <- ifelse(train_pred > 0.5,1,0)

table(class_doc, train_label)
```

```
##          train_label
## class_doc   0   1
##         0 150   0
##         1   0  50
```

As shown by the 0s, there is perfect prediction - this means the model is over fit.

Question 2.3

Now, use the model to make a prediction for the *test* data and classify using a 0.5 threshold.

Assess the accuracy of your classification by comparing it to the actual test data. What do you notice? What would happen if you randomly guessed the test labels using a prior on the probability of 1 as the proportion of 1s in the train labels? Remember to `set.seed(12019)`. Compare your findings between the two methods.

```
set.seed(12019)

# do same with test

test_pred <- predict(full_ref, as.data.frame(test))
```

```
## Warning in predict.lm(full_ref, as.data.frame(test)): prediction from a rank-
## deficient fit may be misleading
```

```
class_pred <- ifelse(test_pred > 0.5,1,0)

table(class_pred, test_label)
```

```
##           test_label
## class_pred  0  1
##          0 31 17
##          1 31  9
```

```
# test the accuracy


accuracy <-sum(class_pred==test_label) / length(test_label)
accuracy
```

```
## [1] 0.4545455
```

```
# randomly guess to see if using the model makes for a better prediction than random
random_guess <- rbinom(length(test_label),
                       prob = sum(train_label)/length(train_label),
                       size = 1)
accuracy2 <- sum(diag(table(random_guess, test_label)))/length(test_label)
accuracy2
```

```
## [1] 0.6704545
```

The random guess is accuracy about 61% of the time and the model I made is accuracy about 45% of time - the model is WORSE than random.

3. Fit LASSO regression

Question 3.1

We are going to use the `glmnet` library to fit the LASSO regression. Load the package.

The syntax for the glmnet model is as follows: `lasso <- glmnet(x = train, y = train_label)`

This defaults to linear regression. To do logistic regression you can fit the same model, but add `lasso_logist <- glmnet(x = train, y = train_label, family = 'binomial')`

Fit a LASSO linear regression.

```
# install package glm net
library(glmnet)
```

```
## Loading required package: Matrix
```

```
##
## Attaching package: 'Matrix'
```

```
## The following objects are masked from 'package:tidyr':
##
##     expand, pack, unpack
```

```
## Loaded glmnet 4.1-3
```

```
set.seed(12019)

lasso <- glmnet(x = train, y = train_label)
```

Question 3.2

The LASSO function automatically fits the model for several values of λ, and produces β values for all covariates for each value of λ all of which is found in the object `lasso$beta`.

Sum up the absolute values of `lasso$beta` for each column. Plot that against `lasso$lambda`. What generally happens as λ increases?

```
# create a sum that includes absolute value of betas
sum_beta <- colSums(abs(lasso$beta))

# plot beta versus lambda

plot(sum_beta ~ lasso$lambda, pch=16, col = "red", xlab = "Lambda", ylab = "Sum of Betas")
```

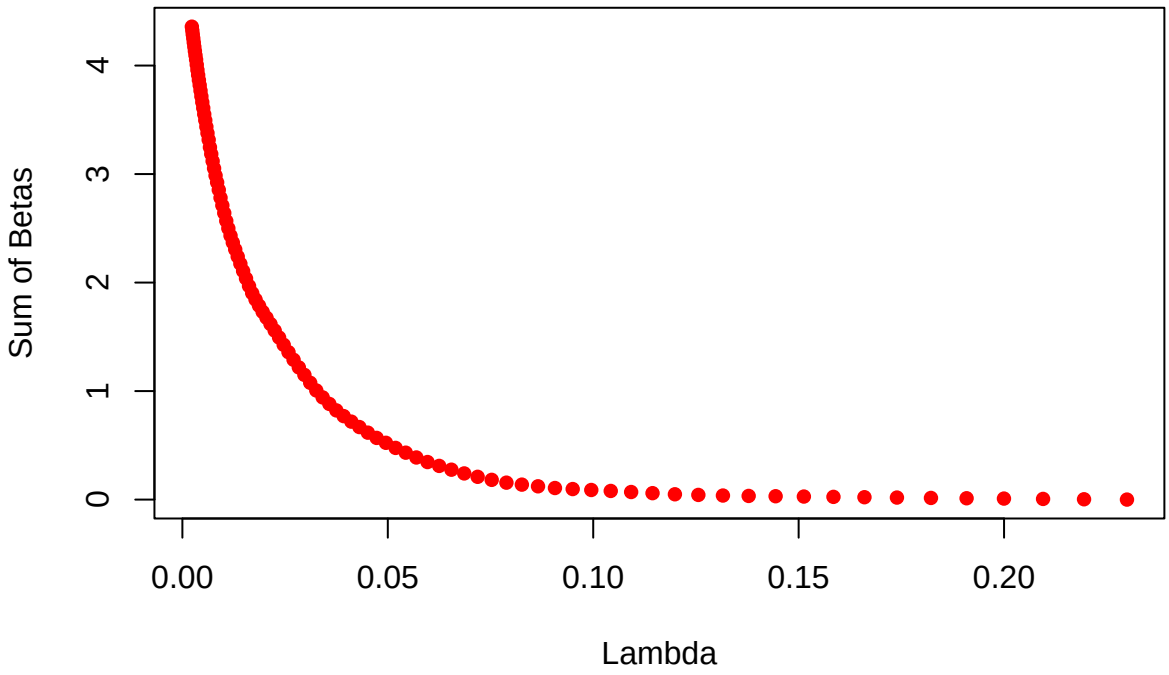

Question 3.3

There are different methods to selecting lambda, which we set aside for another day. Today, we're going to set a particular value of lambda arbitrarily and then assess its performance. We will set lambda to 0.05.

Formulate predictions for the training set using the following syntax: `lasso_pred <- predict(lasso, newx=train, s = 0.05 )`

- `lasso` is the lasso regression
- `newx` are the values you want to predict
- `s` is the value of lambda.

Classify the observations using a threshold of 0.5. Then assess the accuracy of those predictions by comparing them to the training set labels and create a confusion matrix. Do the same but use a threshold of prior information on the training set – the proportion of 1s. Which threshold is better?

```
# do the same as 2.3 but with lasso
# formulate predictions
# classify obs using threshold of 0.5
# create confusion matrix
# get accuracy score


lasso_pred <- predict(lasso, newx=train, s = 0.05 )
class_lasso1 <- ifelse(lasso_pred>0.5, 1, 0)
table(class_lasso1, train_label)
```

```
##             train_label
## class_lasso1   0   1
##            0 149  18
##            1   1  32
```

```
(sum(class_lasso1 & train_label) + sum(!class_lasso1 & !train_label)) / length(train_label)
```

```
## [1] 0.905
```

```
# classify obs using threshold with prior
# create confusion matrix
# get accuracy score

class_lasso2 <- ifelse(lasso_pred>sum(train_label)/length(train_label), 1, 0)
table(class_lasso2, train_label)
```

```
##             train_label
## class_lasso2   0   1
##            0 137   4
##            1  13  46
```

```
(sum(class_lasso2 & train_label) + sum(!class_lasso2 & !train_label)) / length(train_label)
```

```
## [1] 0.915
```

0.91 and 0.9 are not perfect which means that there is less model dependence than before. These values are also different from eachother which means that using a threshold matters.

Question 3.4

Now formulate predictions for the test set, classify the documents as national or not with a threshold using the prior proportion of 1 labels in the training set as well as 0.5, and assess the accuracy of those predictions by comparing them to the test set labels. What do you notice about the quality of the predictions from LASSO relative to the predictions from OLS?

```
# do the same thing as above but with the test data


lasso_test <- predict(lasso, newx=test, s = 0.05 )
class_lasso_test <- ifelse(lasso_test>sum(train_label)/length(train_label), 1, 0)
table(class_lasso_test, test_label)
```

```
##                 test_label
## class_lasso_test  0  1
##                0 53  6
##                1  9 20
```

```
accuracy3 <- (sum(class_lasso_test & test_label) + sum(!class_lasso_test & !test_label)) / length(test_l
accuracy3
```

```
## [1] 0.8295455
```

```
# classify obs using threshold of 0.5
class_lasso_test2 <- ifelse(lasso_test>sum(train_label)/length(train_label), 1, 0)
table(class_lasso_test2, test_label)
```

```
##                  test_label
## class_lasso_test2  0  1
##                 0 53  6
##                 1  9 20
```

```
accuracy4<-(sum(class_lasso_test2 & test_label) + sum(!class_lasso_test2 & !test_label)) / length(test_l
accuracy4
```

```
## [1] 0.8295455
```

The accuracy for this model is around 83% which is much higher than the 45% of the original model. That being said, this accuracy is less than that of the model with the training data indicating that there is slight model dependence.